ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Nhập môn học máy

Report Lab02: Linear Regression Project

Đề tài: Phân tích và dự đoán giá bất động sản bằng mô hình hồi quy tuyến tính

Giảng viên hướng dẫn: TS. Bùi Tiến Lên
ThS. Lê Nhựt Nam
ThS. Võ Nhật Tân

Sinh viên: Phạm Khánh Linh - 23127083
Võ Trung Hiếu - 23127190
Nguyễn Thành Lợi - 23127408
Lê Quốc Thiện - 23127481
Phạm Quang Thịnh - 23127485
Lớp: 23KHDL1

THÀNH PHỐ HỒ CHÍ MINH, 5 THÁNG 04 2026

Mục lục

1 Mô tả bài toán và động lực (Problem Description and Motivation) 1
1.1 Bối cảnh và động lực 1
1.2 Mục tiêu dự đoán 1

2 Mô tả và khám phá dữ liệu (Data Description and Exploration) 2
2.1 Nguồn gốc và đặc tả dữ liệu 2
2.2 Phân tích Khám phá Dữ liệu (EDA) 2
2.2.1 Phân phối biến mục tiêu và đặc trưng số 2
2.2.2 Ma trận tương quan và Tính tuyến tính 4
2.2.3 Phân hóa theo các yếu tố định tính (Địa lý và Pháp lý) 5

3 Tiền xử lý dữ liệu (Data Preprocessing) 6
3.1 Chuẩn hóa dữ liệu thô (Data Cleaning) 6
3.2 Xử lý Outliers và Biến đổi dữ liệu (Handling Outliers & Transformation) 6
3.3 Trích xuất và Tối ưu hóa đặc trưng (Feature Engineering) 7
3.4 Cấu trúc dữ liệu cuối cùng 8

4 Xây dựng mô hình và thiết kế (Model Design and Construction) 8
4.1 Mô hình Baseline: Hồi quy tuyến tính cơ bản (Base Model) 8
4.2 Mô hình 1: Mô hình hồi quy đa biến tích hợp tương tác và đa thức (Log-Log, Polynomial & Interaction) 9
4.3 Mô hình 2: Hồi quy tuyến tính tích hợp Target Encoding cấp Phường và Tương tác Không gian 10
4.4 Mô hình 3: Mô hình hồi quy đa biến nâng cao với đa thức bậc cao, tương tác và biến đổi Log-Log 12
4.5 Mô hình 4: Hồi quy tuyến tính đa biến kết hợp trích xuất đặc trưng văn bản 13
4.6 Mô hình 5: Tối ưu hóa tương tác không gian và khử nhiễu mật độ (Advanced Spatial Interaction & Density Denoising Model) 13

5 Đánh giá và so sánh kết quả (Evaluation and Comparison of Results) 15
5.1 Các thang đo đánh giá (Metrics) 15
5.2 Kiểm chứng chéo (Cross-Validation) 16
5.3 Điểm mạnh và Điểm yếu 16

6 Giải thích kết quả và góc nhìn sâu sắc (Interpretation and Insights) 18
6.1 Giải thích hệ số hồi quy (Interpreting Coefficients) 18
6.2 Yêu cầu cốt lõi 19
6.3 Những phát hiện (Insights) từ mô hình 20

7 Ứng dụng dự toán (Application Development) 21
7.1 Mô tả giao diện 21
7.2 Tính năng chính 21
7.3 Trực quan hóa kết quả 22

8 Kết luận (Conclusion) 24
8.1 Tổng kết kết quả đạt được 24
8.2 Hạn chế của mô hình 24

Tài liệu tham khảo 25

1 Mô tả bài toán và động lực (Problem Description and Motivation)

1.1 Bối cảnh và động lực

Thị trường bất động sản là một hệ thống phức tạp với giá trị tài sản biến động dựa trên nhiều yếu tố định lượng và định tính. Việc xác định giá trị nhà đất theo cách truyền thống thường mang tính cảm tính hoặc dựa trên kinh nghiệm cá nhân, dẫn đến sự thiếu đồng nhất.

Nhóm chúng tôi thực hiện dự án này với các động lực chính sau:

- Xây dựng công cụ hỗ trợ người dùng (người mua/bán) tham khảo giá thị trường một cách khách quan, giảm thiểu rủi ro về thông tin.
- Dữ liệu bất động sản có cấu trúc rõ ràng, đa dạng biến số, rất phù hợp để minh họa sức mạnh của các mô hình hồi quy trong việc tìm ra quy luật từ dữ liệu thực tế.
- Ứng dụng giúp các đơn vị môi giới hoặc ngân hàng tự động hóa quy trình thẩm định giá sơ bộ, tiết kiệm thời gian và chi phí nhân sự.

1.2 Mục tiêu dự đoán

Mục tiêu cụ thể của bài báo cáo là xây dựng mô hình hồi quy tuyến tính để dự báo giá trị bất động sản. Bài toán được xác định cụ thể như sau:

- **Biến mục tiêu (Target variable):** Giá trị bất động sản (ký hiệu là Y). Tùy theo đặc thù bộ dữ liệu, Y có thể là tổng giá trị tài sản (tỷ VNĐ) hoặc đơn giá (m^2). Đây là biến định lượng liên tục.
- **Các biến đầu vào (Input features):** Tập hợp các đặc trưng X ảnh hưởng đến giá, bao gồm:
  - Nhóm vật lý: Diện tích sử dụng, số phòng ngủ, số tầng, chiều rộng mặt tiền.
  - Nhóm vị trí và pháp lý: Quận/Huyện, loại hình nhà ở, tình trạng sổ đỏ.

Kết quả của mô hình không chỉ dừng lại ở con số dự báo mà còn giúp phân tích tầm quan trọng của từng đặc trưng (ví dụ: yếu tố Vị trí hay Diện tích đóng góp nhiều hơn vào giá trị nhà), từ đó đưa ra các góc nhìn sâu sắc về thị trường.

2 Mô tả và khám phá dữ liệu (Data Description and Exploration)

2.1 Nguồn gốc và đặc tả dữ liệu

Dữ liệu được tích hợp từ hai nguồn chính là *batdongsan.com.vn* và *thuviennhadat.vn*. Sau khi gộp và loại bỏ các tin đăng trùng lặp, bộ dữ liệu sau xử lý sơ bộ phục vụ phân tích bao gồm **10.018 quan sát**. Các biến quan trọng bao gồm: *Giá, Diện tích, Số phòng ngủ, Sô phòng tắm, Số tầng, Pháp lý* và *Địa chỉ*.

2.2 Phân tích Khám phá Dữ liệu (EDA)

2.2.1 Phân phối biến mục tiêu và đặc trưng số

Qua trực quan hóa bằng biểu đồ Histogram, Q-Q Plot (Hình 2.1) và hệ thống Boxplot (Hình 2.2), nhóm ghi nhận các đặc điểm quan trọng:

- **Độ lệch cực đoan:** Biến mục tiêu (`gia`) bị lệch phải rất nặng ($Skewness = 65.88$), các điểm dữ liệu rời rạc trong Q-Q Plot cho thấy sự vi phạm nghiêm trọng giả định phân phối chuẩn.
- **Sự hiện diện của Outliers:** Biểu đồ Boxplot phát hiện nhiều điểm dị biệt "khủng" như bất động sản có giá trên 5.000 tỷ đồng hoặc số lượng phòng ngủ/tắm vượt mức 300 phòng. Đây là các nhiễu dữ liệu cần loại bỏ để tránh làm sai lệch đường hồi quy OLS.

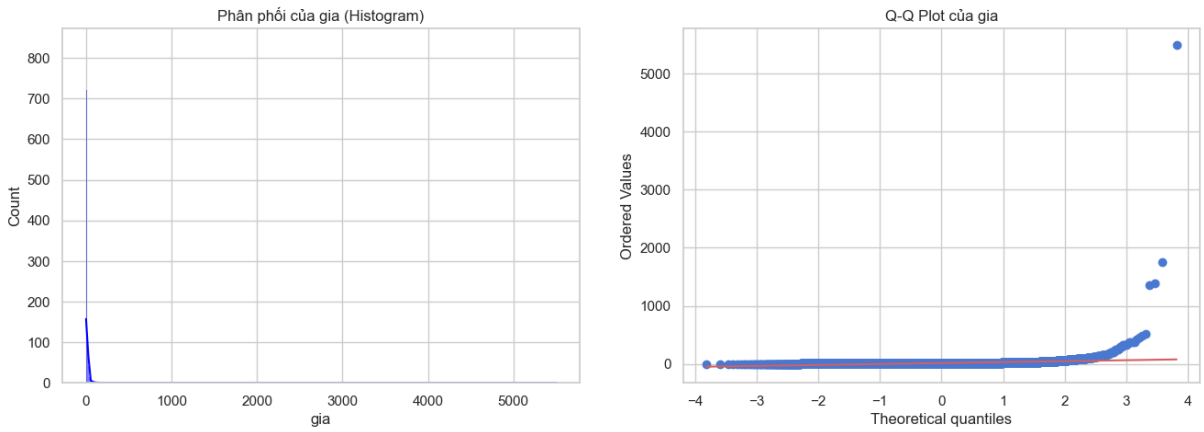

Figure 2.1: Phân phối biến mục tiêu gia và biểu đồ Q-Q Plot trước khi xử lý

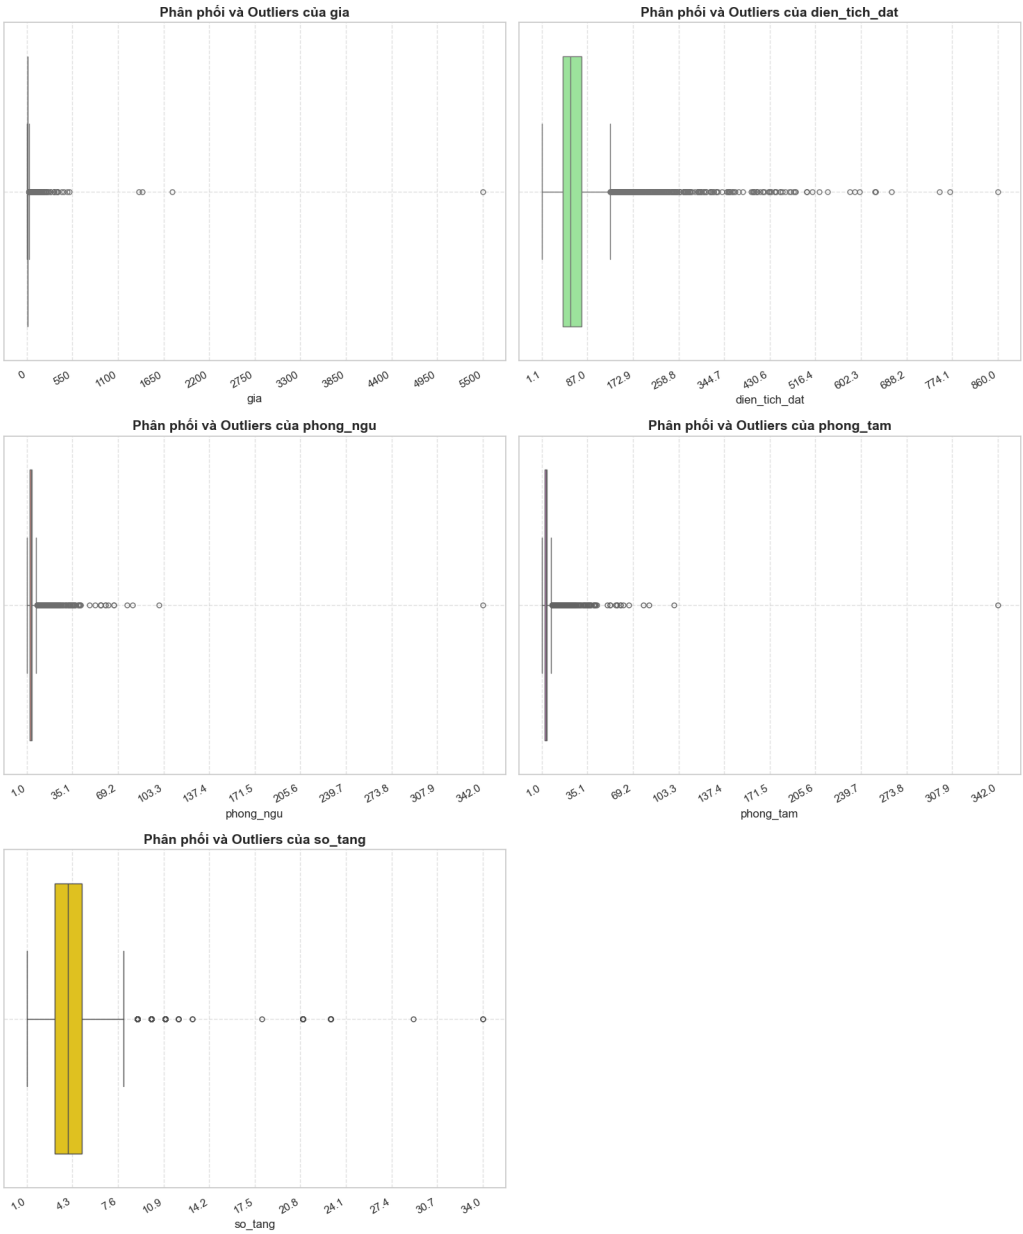

Figure 2.2: Nhận diện Outliers trên các đặc trưng số thông qua Boxplot

2.2.2 Ma trận tương quan và Tính tuyến tính

- **Tương quan và Đa cộng tuyến:** Dựa trên Ma trận nhiệt (Hình 2.3), diện tích ($r = 0.59$) và số tầng ($r = 0.57$) là hai đặc trưng có tương quan thuận mạnh nhất với giá nhà. Đặc biệt, nhóm ghi nhận hệ số tương quan rất cao giữa số phòng ngủ và phòng tắm ($r = 0.86$), dấu hiệu của hiện tượng **đa cộng tuyến** cần lưu ý khi chọn các biến đầu vào cho mô hình.

- **Tính tuyến tính:** Biểu đồ phân tán (Hình 2.4) cho thấy dữ liệu gốc gặp hiện tượng phương sai thay đổi (loe rộng hình phễu). Tuy nhiên, khi áp dụng thang đo **Log-Log**, mối quan hệ giữa diện tích và giá trở nên tuyến tính rõ rệt và bám sát đường hồi quy, khẳng định tính hiệu quả của phép biến đổi Logarit.

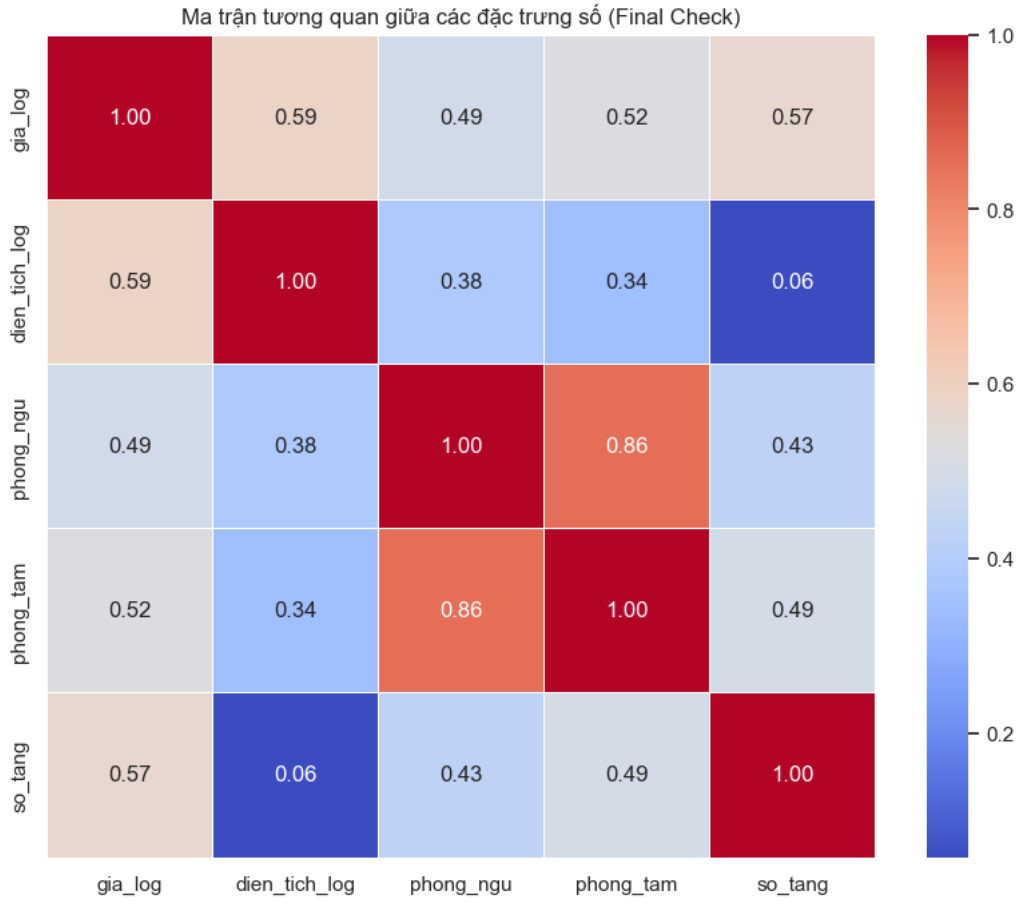

Figure 2.3: Ma trận tương quan giữa các đặc trưng số

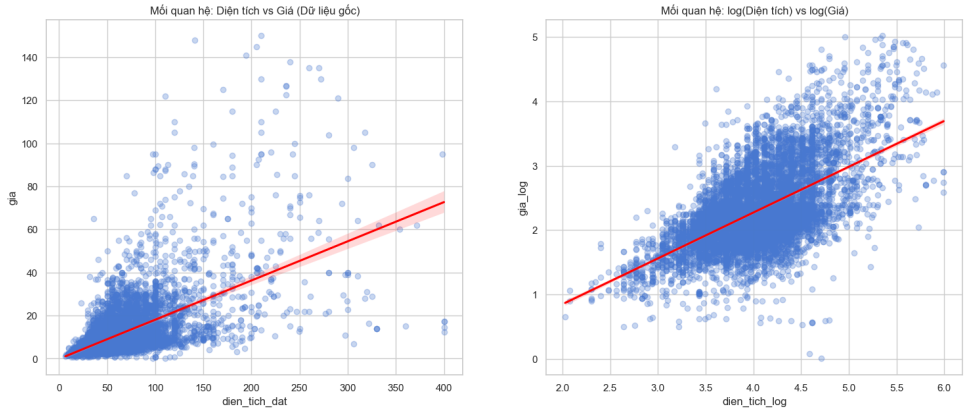

Figure 2.4: So sánh tính tuyến tính của dữ liệu ở thang đo gốc và thang đo Log-Log

2.2.3 Phân hóa theo các yếu tố định tính (Địa lý và Pháp lý)

Phân tích các đặc trưng định tính thông qua biểu đồ Boxplot (Hình 2.5) và đơn giá khu vực (Hình 2.6) cho thấy những Insight quan trọng về thị trường:

- **Yếu tố địa lý:** Mặt bằng giá nhà tại Hà Nội cao hơn rõ rệt so với TP.HCM trên thang đo Log. Đáng chú ý, toàn bộ Top 10 khu vực có đơn giá trung bình cao nhất đều thuộc Hà Nội (vượt ngưỡng 0.5 tỷ/m^2 tại quận Hoàn Kiếm), khẳng định vị thế "điểm nóng" của thị trường này.
- **Yếu tố pháp lý:** Nhóm bất động sản "Đã có sổ" không chỉ có giá trị cao hơn mà còn có dải giá ổn định hơn. Nhóm ghi nhận sự mất cân bằng dữ liệu nghiêm trọng ở biến này (8.844 mẫu Sổ hồng vs 24 mẫu Sổ đỏ). Để tối ưu cho mô hình hồi quy, nhóm thực hiện gộp hai hạng mục này thành nhóm chung mang tên **"Đã có sổ"** nhằm loại bỏ sự thưa thớt (Data Sparsity) và tránh hiện tượng quá khớp (Overfitting).

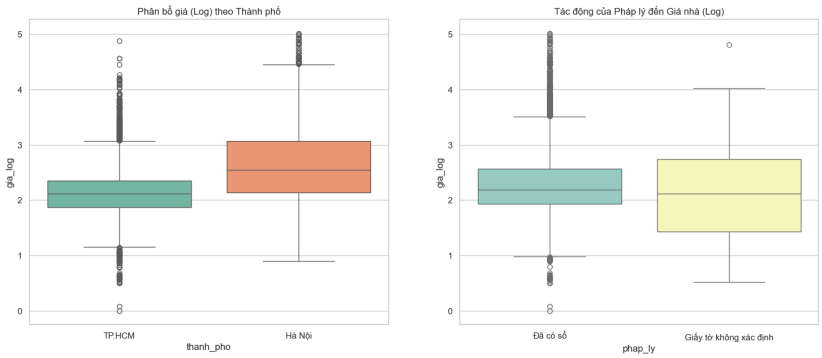

Figure 2.5: Phân bổ giá nhà theo Thành phố và Tình trạng pháp lý

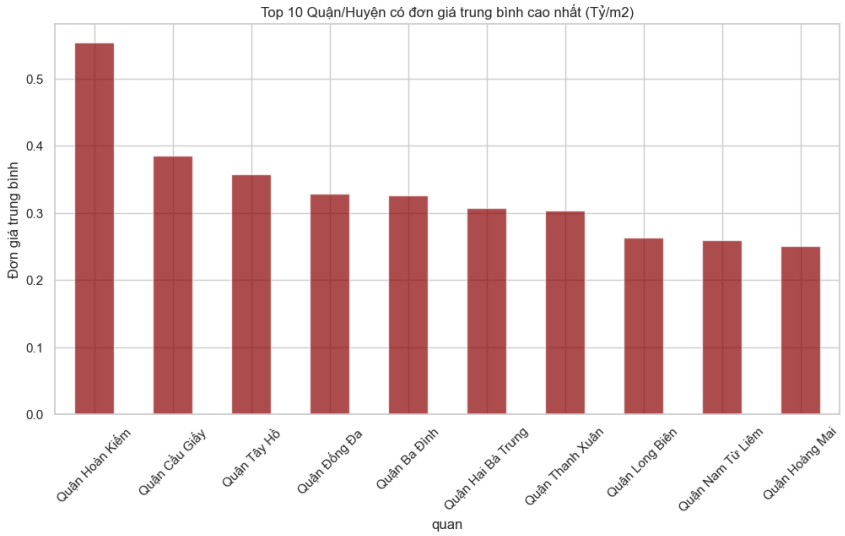

Figure 2.6: Top 10 Quận/Huyện có đơn giá trung bình cao nhất (Tỷ/m^2)

3 Tiền xử lý dữ liệu (Data Preprocessing)

3.1 Chuẩn hóa dữ liệu thô (Data Cleaning)

- **Chuyển đổi kiểu dữ liệu:** Sử dụng Regex để trích xuất số từ chuỗi văn bản cho diện tích, giá và số tầng. Đặc biệt, xử lý sự không đồng nhất giữa dấu phẩy (,) và dấu chấm (.) trong định dạng thập phân của giá.
- **Xử lý thời gian:** Chuyển đổi `ngay_dang` sang `datetime64` bằng kỹ thuật `mixed format` để cứu tối đa dữ liệu lỗi định dạng.

3.2 Xử lý Outliers và Biến đổi dữ liệu (Handling Outliers & Transformation)

Đặc trưng	**50% (Med)**	**75%**	**90%**	**95%**	**99%**
gia (tỷ VNĐ)	8.0	13.0	24.53	36.0	95.0
dien_tich_dat (m^2)	55.0	76.0	105.0	145.0	300.0
phong_ngu	4.0	5.0	6.00	8.0	19.0
phong_tam	4.0	5.0	6.00	9.0	19.0
so_tang	4.0	5.0	7.00	8.0	10.0

Table 3.1: Thống kê các mốc phân vị (Percentiles) để xác định ngưỡng cắt Outliers

Dựa trên bảng phân vị (Percentiles), nhóm thực hiện các bước xử lý sau để làm sạch và chuẩn hóa dữ liệu:

- **Lọc Outliers:** Nhóm loại bỏ khoảng 3% dữ liệu cực đoan không mang tính đại diện cho bất động sản dân cư thông thường (Giá > 150 tỷ, Diện tích > $400m^2$, số phòng > 15, Số tầng > 10). Bước này giúp loại bỏ nhiễu hệ thống, đưa Skewness của biến `gia` từ 65.88 xuống còn 4.62 (Hình 3.1).
- **Biến đổi Logarit:** Để khắc phục hiện tượng lệch phải ở Giá và Diện tích, nhóm áp dụng phép biến đổi $y' = \ln(1+y)$ cho cả Giá và Diện tích. Kết quả thu được là phân phối tiệm cận chuẩn (Hình 3.5) với Skewness lý tưởng (≈ 0.98 cho giá và 0.32 cho diện tích), đảm bảo giả định cốt lõi của mô hình Hồi quy Tuyến tính.

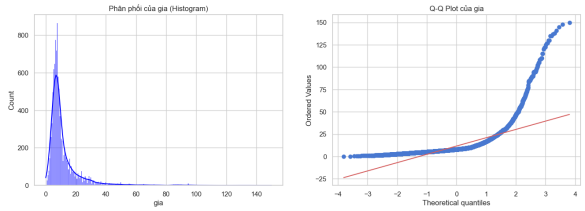

Figure 3.1: Giá trước khi Log-transform (Skew = 4.62)

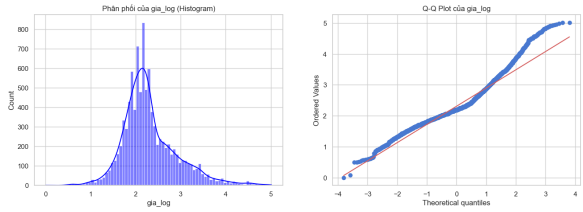

Figure 3.2: Giá sau Log-transform (Skew = 0.98)

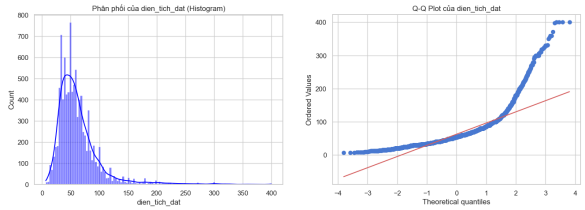

Figure 3.3: Diện tích gốc (Skew = 2.99)

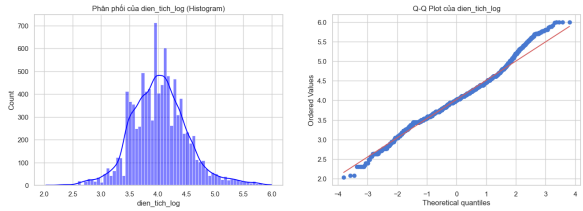

Figure 3.4: Diện tích sau Log-transform (Skew = 0.32)

Figure 3.5: Minh họa hiệu quả của phép biến đổi Logarit lên biến mục tiêu và đặc trưng quan trọng nhất

3.3 Trích xuất và Tối ưu hóa đặc trưng (Feature Engineering)

- **Trích xuất Vị trí:** Sử dụng Regex để tách địa chỉ thô thành hai cấp độ: **Thành phố** và **Quận/Huyện**.

- **Gom nhóm hạng mục hiếm:** Các Quận/Huyện có dưới 20 mẫu được gộp vào nhóm "Quận/Huyện khác" để tránh quá khớp (Overfitting). Nhóm "Sổ đỏ" (ít mẫu) được gộp vào "Sổ hồng" do tương đồng về giá trị kinh tế.

3.4 Cấu trúc dữ liệu cuối cùng

Sau tiền xử lý, nhóm thu được tập dữ liệu sạch gồm **9.116 quan sát**. Để đảm bảo tính đa dạng cho 5 thành viên đề xuất mô hình, nhóm giữ lại cả biến gốc và biến Logarit trong file dữ liệu cuối cùng.

Tên biến	**Loại dữ liệu**	**Ý nghĩa**
gia (Target)	Numeric (tỷ VNĐ)	Tổng giá trị bất động sản niêm yết.
dien_tich_dat	Numeric (m^2)	Diện tích đất được công nhận.
phong_ngu/tam	Discrete (số)	Số lượng phòng ngủ và phòng tắm.
so_tang	Discrete (số)	Tổng số tầng của bất động sản.
quan/thanh_pho	Categorical	Vị trí địa lý cấp Quận/Huyện và Thành phố.
phap_ly	Categorical	Tình trạng sổ hồng, sổ đỏ hoặc chưa xác định.

Table 3.2: Đặc tả các biến trong bộ dữ liệu Master

Đồng thời, tập dữ liệu được phân chia sẵn thành tập Train (80%) và tập Test (20%) với tham số `random_state=42` nhằm đảm bảo tính tái lập của kết quả. Nhận thấy sự chênh lệch về số lượng quan sát giữa hai thị trường TP.HCM và Hà Nội, nhóm đã áp dụng kỹ thuật **lấy mẫu phân tầng (Stratified Sampling)** dựa trên đặc trưng `thanh_pho` để đảm bảo tỷ lệ đại diện của từng vùng miền trong cả hai tập dữ liệu là đồng nhất, giúp việc so sánh hiệu suất giữa 5 mô hình của các thành viên trở nên khách quan và phản ánh chính xác khả năng tổng quát hóa trên toàn thị trường.

4 Xây dựng mô hình và thiết kế (Model Design and Construction)

4.1 Mô hình Baseline: Hồi quy tuyến tính cơ bản (Base Model)

Đây là mô hình đơn giản nhất, được thiết lập nhằm tạo ra một mốc hiệu suất tham chiếu (benchmark). Mô hình này giúp nhóm đánh giá mức độ cải thiện của các kỹ thuật nâng cao so với cách tiếp cận bản năng nhất. Các đặc điểm chính bao gồm:

- **Tập đặc trưng vật lý:** Sử dụng các biến số trực quan nhất đại diện cho quy mô và cấu trúc của bất động sản bao gồm: diện tích (`dien_tich_dat`), số phòng ngủ (`phong_ngu`), số phòng tắm (`phong_tam`) và số tầng (`so_tang`).
- **Xử lý dữ liệu gốc:** Khác với các mô hình nâng cao, Baseline được huấn luyện trực tiếp trên thang đo đơn vị gốc (tỷ VNĐ và m^2). Nhóm không áp dụng các kỹ thuật biến đổi Logarit hay mã hóa vị trí địa lý, nhằm kiểm chứng sức mạnh dự báo thuần túy của các thông số xây dựng cơ bản.
- **Phương trình hồi quy tổng quát:** Dựa trên kết quả huấn luyện bằng thuật toán OLS, mô hình xác lập mối quan hệ tuyến tính cộng dồn có dạng:

$$\hat{Y}(Gi) = \beta_0 + \beta_1 X_{Area} + \beta_2 X_{Bed} + \beta_3 X_{Bath} + \beta_4 X_{Floor} \tag{4.1}$$

Mô hình Baseline cung cấp một cái nhìn sơ khởi về thị trường: diện tích lớn hơn và nhiều tầng hơn thường đi kèm với mức giá cao hơn. Tuy nhiên, do bỏ qua yếu tố vị trí địa lý và các quan hệ phi tuyến, mô hình này được kỳ vọng sẽ có sai số cao, làm nền tảng để so sánh với sự ưu việt của các mô hình phức tạp phía sau.

4.2 Mô hình 1: Mô hình hồi quy đa biến tích hợp tương tác và đa thức (Log-Log, Polynomial & Interaction)

Dựa trên kết quả EDA, mô hình 1 được xây dựng để tập trung tối ưu hóa theo Vị trí và Diện tích, với các biến đổi đặc trưng nhằm phản ánh tốt hơn quy luật của giá bất động sản. Các ý tưởng chính như sau:

- **Cấu trúc Log-Log:** Áp dụng phép log cho cả giá (`gia_log`) và diện tích (`dien_tich_log`). Vì giá và diện tích có phạm vi giá trị rất lớn và phân bố không đều, cần chuyển chúng về dạng log để giảm sự chênh lệch quá lớn giữa các giá trị, làm cho dữ liệu phân bố đều hơn, giúp mô hình học ổn định hơn, diễn giải kết quả dễ hơn (hệ số hồi quy thể hiện *tỷ lệ phần trăm thay đổi* của giá khi diện tích thay đổi).
- **Đặc trưng đa thức:** Bổ sung biến `dien_tich_poly2` (bình phương của `dien_tich_log`) để mô hình nắm bắt quan hệ phi tuyến giữa diện tích và giá vì có thể thực tế giá không tăng đều theo diện tích. Thêm thành phần bình phương giúp mô hình học được dạng quan hệ cong, từ đó phản ánh chính xác hơn xu hướng biến động của giá theo diện tích.

- **Tương tác theo vị trí:** Tạo biến tương tác giữa `dien_tich_log` và các quận/huyện. Việc này cho phép mô hình không áp dụng một mối quan hệ chung giữa diện tích và giá cho tất cả khu vực, mà điều chỉnh theo từng quận/huyện. Nhờ đó, mô hình phản ánh tốt hơn sự khác biệt về mức giá theo diện tích giữa các vị trí khác nhau trên thị trường.

- **Tinh giản đặc trưng:** Để tránh đa cộng tuyến, loại bỏ `phong_ngu` do tương quan cao với `phong_tam` (0,86).Tương tự, loại bỏ `thanh_pho` vì thông tin đã được thể hiện qua biến quận/huyện.

Mô hình này được xây dựng nhằm khai thác hiệu quả hai yếu tố quan trọng nhất của bất động sản là diện tích và vị trí, thông qua các biến đổi như log, đa thức và tương tác. Chúng giúp mô hình nắm bắt tốt hơn mối quan hệ phi tuyến và sự khác biệt giữa các khu vực, từ đó cải thiện độ chính xác dự đoán. Đồng thời, mô hình vẫn giữ được tính ổn định và khả năng diễn giải, phù hợp cho việc phân tích và ứng dụng trong thực tế.

4.3 Mô hình 2: Hồi quy tuyến tính tích hợp Target Encoding cấp Phường và Tương tác Không gian

Mô hình 2 được xây dựng nhằm giải quyết một hạn chế cốt lõi mà các mô hình trước chưa khai thác triệt để: **độ phân giải không gian địa lý**. Thay vì mã hóa vị trí chỉ ở cấp Quận/Huyện như thông thường, mô hình đẩy cao độ chính xác định vị lên cấp **Phường** — đơn vị hành chính phản ánh sát nhất giá trị bất động sản cục bộ. Các ý tưởng thiết kế chính như sau:

- **Trích xuất vị trí cấp Phường từ dữ liệu văn bản:** Sử dụng biểu thức chính quy (Regex) để bóc tách tên Phường/Xã từ cột địa chỉ thô `dia_chi`. Từ đó, tạo khóa định danh kép `quan_phuong` (ví dụ: `"Quận 3_Phường 1"`) nhằm xây dựng bản đồ giá trị không gian có độ phân giải cao hơn hẳn so với việc chỉ dùng cấp Quận.

- **Smoothed Target Encoding hai tầng (Quận và Phường):** Thay vì mã hóa One-Hot đơn thuần cho biến vị trí — vốn tạo ra hàng chục cột nhị phân thưa thớt — mô hình áp dụng kỹ thuật *Smoothed Target Encoding* để nhúng trực tiếp thông tin giá thị trường vào mỗi vị trí địa lý. Cụ thể, giá trị trung bình m^2 được tính cho từng Phường và từng Quận theo công thức làm mượt:

$$\hat{\mu}_k = \frac{n_k \cdot \bar{y}_k + w \cdot \bar{y}_{\text{global}}}{n_k + w}$$

trong đó n_k là số mẫu tại nhóm k, $\bar{y}_k$ là trung bình giá m^2 của nhóm, $\bar{y}_{\text{global}}$ là trung bình toàn cục, và w là hệ số làm mượt (weight). Hệ số w được đặt cao hơn cho cấp Quận ($w = 10$) và thấp hơn cho cấp Phường ($w = 1$), phản ánh mức độ thưa thớt dữ liệu ở từng cấp. Toàn bộ thống kê này chỉ được tính trên tập Train và áp dụng sang tập Test để tránh rò rỉ thông tin (Data Leakage).

- **Cơ chế dự phòng thông minh (Fallback):** Một thách thức thực tế là tập Test có thể chứa các Phường chưa từng xuất hiện trong tập Train. Để xử lý trường hợp này, mô hình tích hợp cơ chế tự động: nếu một Phường mới không tìm thấy trong bản đồ mã hóa, giá trị `gia_m2_tb_phuong` sẽ được thay thế bằng giá trị trung bình của Quận tương ứng (`gia_m2_tb_quan`). Chiến lược này đảm bảo mô hình không bao giờ gặp giá trị `NaN` khi dự báo trong thực tế.

- **Biến tương tác không gian (Spatial Interaction Feature):** Thay vì chỉ đưa các đặc trưng vị trí và diện tích vào mô hình một cách độc lập, mô hình tạo biến tương tác `tuong_tac_dt_vt` bằng cách nhân chéo `dien_tich_log` với `gia_m2_tb_phuong_log`. Điều này cho phép mô hình học được rằng *mối quan hệ giữa diện tích và giá không đồng nhất giữa các vị trí*: cùng một mét vuông tăng thêm sẽ đóng góp giá trị khác nhau tùy theo Phường — hoàn toàn phản ánh đúng thực tế thị trường.

- **Tổng hợp đặc trưng và mã hóa biến phân loại:** Tập đặc trưng cuối cùng bao gồm `dien_tich_log`, `tong_so_phong` (tổng số phòng ngủ và phòng tắm), `so_tang`, `gia_m2_tb_phuong_log`, `tuong_tac_dt_vt`, cùng các biến phân loại `phap_ly`, `quan`, `thanh_pho` được mã hóa One-Hot. Kỹ thuật `reindex` được áp dụng để đồng bộ cấu trúc cột giữa tập Train và tập Test, đảm bảo tính nhất quán khi dự báo. Đáng lưu ý, biến `phong_ngu` và `phong_tam` được hợp nhất thành `tong_so_phong` để giảm thiểu đa cộng tuyến (do hai biến này có hệ số tương quan $r = 0.86$), đồng thời vẫn bảo toàn thông tin về quy mô sử dụng của bất động sản.

Mô hình sử dụng thuật toán Hồi quy Tuyến tính OLS (`LinearRegression` của scikit-learn) trên không gian đặc trưng đã được thiết kế kỹ lưỡng. Kết quả huấn luyện cho thấy mô hình đạt $R^2 \approx 0.7551$ trên tập kiểm tra, với sai số tuyệt đối trung bình (MAE) khoảng **2.6 tỷ VNĐ**. Biến `gia_m2_tb_phuong_log` đóng vai trò là đặc trưng bứt phá chủ lực, giúp mô hình nắm bắt được sự phân hóa giá trị bất động sản ở độ phân giải không gian cao mà không cần tăng độ phức tạp của thuật toán.

4.4 Mô hình 3: Mô hình hồi quy đa biến nâng cao với đa thức bậc cao, tương tác và biến đổi Log-Log

Mô hình tập trung tối ưu hóa dự đoán giá bằng cách kết hợp biến đổi Log-Log, đa thức bậc cao (polynomial features) và các tương tác giữa các đặc trưng số. Các ý tưởng chính được áp dụng như sau:

- **Cấu trúc Log-Log:** Tiếp tục áp dụng phép biến đổi log tự nhiên cho biến mục tiêu `gia_log` và biến diện tích `dien_tich_log`. Việc này giúp giảm thiểu ảnh hưởng của phân bố lệch phải (skewed distribution) thường thấy trong dữ liệu giá nhà và diện tích – vốn có phạm vi giá trị rất rộng. Nhờ log, mối quan hệ giữa diện tích và giá trở nên gần tuyến tính hơn. Tuy nhiên, khi kết hợp với các đặc trưng đa thức, việc diễn giải trực tiếp hệ số hồi quy trở nên phức tạp hơn so với mô hình log-log đơn giản.

- **Đặc trưng đa thức (Polynomial Features):** Sử dụng `PolynomialFeatures` bậc 2 (degree=2) trên các biến số chính để mô hình có khả năng học được các quan hệ phi tuyến tính. Cụ thể, bình phương của `dien_tich_log` và các tương tác bậc hai giữa diện tích với số phòng ngủ, phòng tắm, số tầng giúp nắm bắt hiện tượng như "giá tăng mạnh ở mức diện tích vừa phải nhưng chậm lại khi diện tích quá lớn" hoặc "tác động kết hợp giữa diện tích và số tầng". Điều này khắc phục hạn chế của mô hình tuyến tính thuần túy.

- **Tương tác giữa các biến:** Các biến tương tác bậc hai được tạo ra giữa các đặc trưng số như diện tích, số phòng ngủ, phòng tắm và số tầng thông qua PolynomialFeatures. Nhờ đó, mô hình có thể học được các mối quan hệ kết hợp giữa các yếu tố này thay vì giả định chúng độc lập. Điều này phản ánh đúng thực tế thị trường: cùng một diện tích nhưng ở quận trung tâm sẽ có mức giá và độ nhạy khác hẳn so với ngoại ô.

Mô hình 3 được thiết kế với mục tiêu cân bằng giữa độ phức tạp và khả năng diễn giải. Việc kết hợp Log-Log, đa thức và tương tác giúp mô hình nắm bắt tốt hơn các quy luật phi tuyến. Kết quả huấn luyện cho thấy mô hình đạt hiệu suất ổn với chỉ số R^2 khoảng 0.7369 trên tập kiểm tra, chứng tỏ khả năng giải thích khá tốt biến động của giá nhà.

4.5 Mô hình 4: Hồi quy tuyến tính đa biến kết hợp trích xuất đặc trưng văn bản

Mô hình này tập trung khai thác tín hiệu từ dữ liệu văn bản (địa chỉ, tiêu đề) kết hợp với các kỹ thuật tiền xử lý cơ bản để xây dựng một mô hình hồi quy tuyến tính (Linear regression). Dựa trên quá trình triển khai, các bước xử lý chính bao gồm:

- **Trích xuất và chuẩn hóa tên đường:** Sử dụng biểu thức chính quy (regex) để bóc tách tên đường từ cột `dia_chi`, đồng thời loại bỏ các từ nhiễu như số nhà, ngõ ngách. Để tránh làm mô hình bị loãng và giảm thiểu quá khớp, các tên đường xuất hiện dưới 5 lần được gộp thành `Other_Street`. Khi đưa vào huấn luyện, chỉ những đường có trên 50 tin đăng mới được giữ lại để mã hóa one-hot encoding, phần còn lại gộp chung thành `Street_Other`.
- **Tạo đặc trưng từ tiêu đề:** Khai thác trực tiếp cột `tieu_de` để phân tích và tạo ra hai biến phân loại: `is_urgent` (nhận diện nhà cần bán "gấp") và `is_facade` (nhà "mặt tiền" hoặc "kinh doanh"). Đây là những tín hiệu thực tế giúp mô hình nhận biết độ thanh khoản và vị thế của bất động sản.
- **Mã hóa one-hot (One-hot encoding):** Các biến định danh như `ten_duong_clean`, `quan`, và `thanh_pho` được mã hóa one-hot để mô hình có thể học được trọng số riêng cho từng khu vực và tuyến đường.

Mô hình sử dụng thuật toán Linear Regression cơ bản dựa trên bộ đặc trưng đã được trích xuất kỹ lưỡng. Kết quả đánh giá trên tập kiểm tra cho thấy mô hình đạt chỉ số R^2 là 0.7301 (trên thang log) với sai số tuyệt đối trung bình (MAE) ở mức 2.789 tỷ VNĐ. Phân tích hệ số hồi quy cũng chỉ ra rằng vị trí (đặc biệt là quận Hoàn Kiếm, Cầu Giấy, Tây Hồ) và diện tích là những yếu tố có trọng số tác động mạnh nhất đến mức giá dự báo.

4.6 Mô hình 5: Tối ưu hóa tương tác không gian và khử nhiễu mật độ (Advanced Spatial Interaction & Density Denoising Model)

Mô hình 5 đại diện cho một bước tiến quan trọng trong việc tinh chỉnh thuật toán Hồi quy tuyến tính OLS (*Ordinary Least Squares*), tập trung vào việc xử lý các điểm yếu cố hữu của mô hình tuyến tính như tính nhạy cảm với nhiễu và sự cứng nhắc trong việc mô hình hóa các biến số địa lý. Các kỹ thuật tối ưu hóa trọng tâm bao gồm:

- **Khử nhiễu mật độ thông minh (Gaussian Kernel Density Estimation - KDE):** Khác với việc lọc nhiễu (*Outliers*) thông thường dựa trên ngưỡng giá cố định, mô

hình sử dụng thuật toán *Gaussian KDE* để xác định mật độ phân phối xác suất của dữ liệu giá. Cụ thể, mô hình thực hiện loại bỏ các bất động sản có giá trị cực cao ($>$ 80 tỷ VNĐ) nhưng lại nằm trong nhóm 5% mật độ xuất hiện thấp nhất (các điểm cô lập). Kỹ thuật này giúp loại bỏ hiệu quả các "tin đăng ảo", giúp đường hồi quy tập trung vào dải dữ liệu thực tế và ổn định hơn.

- **Mô hình hóa diện tích phi tuyến (Polynomial Area Mapping):** Thay vì giả định giá nhà tăng tuyến tính đơn thuần theo diện tích, mô hình bổ sung đặc trưng bậc hai *dien_tich_log_sq* (bình phương của logarit diện tích). Điều này cho phép thuật toán bắt được quy luật thay đổi của "đơn giá biên" theo quy mô diện tích, phản ánh chính xác hơn các biến động giá theo đường cong trong thực tế.

- **Kỹ thuật Tương tác không gian toàn phần (Full Spatial Interaction):** Đây là kỹ thuật cốt lõi để tối ưu hóa sức mạnh của mô hình. Sau khi thực hiện mã hóa *One-Hot* cho các Quận/Huyện, mô hình tiến hành nhân chéo đặc trưng diện tích (*dien_tich_log*) với từng biến giả (*Dummy variables*) của các Quận. Phép tính này giúp mô hình tự học được các hệ số đơn giá riêng biệt cho từng khu vực địa lý, giải quyết triệt để sự khác biệt về giá trị vị trí (ví dụ: cùng một diện tích nhưng giá trị tại Quận 1 sẽ khác biệt hoàn toàn so với các huyện ngoại thành).

- **Đồng bộ hóa cấu trúc dữ liệu và Mã hóa Danh mục:** Mô hình sử dụng kỹ thuật *Dummy Coding* cho các biến định danh như *quan* (Quận) và *phap_ly* (Pháp lý). Đồng thời, sử dụng hàm `reindex` để đảm bảo tập kiểm tra (*Test set*) có cấu trúc cột hoàn toàn trùng khớp với tập huấn luyện, giúp tránh lỗi sai lệch ma trận và đảm bảo tính nhất quán của các trọng số dự báo.

- **Kiểm soát biến số và Phân tích phần dư:** Mô hình lược bỏ các biến có tính nhiễu cao để tập trung vào các đặc trưng có độ tin cậy lớn. Qua phân phối của phần dư (*Residuals Distribution*), mô hình cho thấy các sai số tập trung dày đặc quanh điểm 0, chứng minh rằng đa số các bất động sản phân khúc đại trà đã được định giá với độ chính xác rất cao.

Kết quả thực nghiệm cho thấy mô hình đạt được sự cân bằng tối ưu giữa độ phức tạp và hiệu suất dự báo, với hệ số xác định đạt mức cao $R^2 \approx 0.7509$. Sai số tuyệt đối trung bình (MAE) đạt 2.6399 tỷ VNĐ, cho thấy khả năng ứng dụng thực tiễn tốt trong việc định giá nhà phố dựa trên các đặc trưng không gian và diện tích đa thức.

5 Đánh giá và so sánh kết quả (Evaluation and Comparison of Results)

5.1 Các thang đo đánh giá (Metrics)

Để đánh giá và so sánh hiệu suất khách quan giữa 5 mô hình, nhóm sử dụng bốn chỉ số định lượng tiêu chuẩn trong hồi quy. Các chỉ số sai số (MAE, MSE, RMSE) được tính trên đơn vị gốc (Tỷ VNĐ) sau khi chuyển đổi ngược từ thang đo Logarit bằng hàm expm1, trong khi R^2 được tính trực tiếp trên thang Logarit để đảm bảo tính nhất quán giữa các mô hình.

- **Hệ số xác định (R^2):** Đo lường tỷ lệ phương sai của biến mục tiêu được giải thích bởi mô hình. Giá trị càng gần 1 thì mô hình càng khớp tốt với dữ liệu.
- **Sai số tuyệt đối trung bình (MAE):** Trung bình độ lệch tuyệt đối giữa giá dự báo và giá thực tế (đơn vị: Tỷ VNĐ). Đây là chỉ số trực quan nhất để đánh giá sai số thực tế trong ứng dụng định giá.
- **Sai số bình phương trung bình (MSE):** Phạt nặng các sai số lớn, phản ánh độ nhạy của mô hình với các điểm dữ liệu ngoại lai (Outliers).
- **Căn bậc hai sai số bình phương trung bình (RMSE):** Cùng đơn vị với MAE nhưng nhạy cảm hơn với sai số cực đoan, hữu ích để phát hiện hiện tượng dự báo lệch tại phân khúc cao cấp.

Bảng 5.1 tổng hợp kết quả đánh giá của cả 5 mô hình trên tập kiểm tra (Test set) gồm 20% dữ liệu được phân tầng theo thành phố.

Table 5.1: So sánh hiệu suất các mô hình trên tập kiểm tra

Mô hình	R^2	**MAE (Tỷ)**	**MSE (Tỷ^2)**	**RMSE (Tỷ)**
Mô hình 1	0.7502	2.6138	**23.7409**	**4.8725**
Mô hình 2	**0.7551**	**2.6011**	25.4065	5.0405
Mô hình 3	0.7369	2.7082	26.1337	5.1121
Mô hình 4	0.7301	2.7893	28.5209	5.3405
Mô hình 5	0.7509	2.6399	24.3795	4.9376

Nhìn chung, cả 5 mô hình đều đạt mức R^2 từ 0.73 đến 0.76, cho thấy sự nhất quán trong chất lượng tổng thể khi cùng xây dựng trên một bộ dữ liệu đã qua tiền xử lý chuẩn hóa. Mô hình 2 dẫn đầu về R^2 và MAE nhờ kỹ thuật Target Encoding cấp Phường giúp mã hóa thông tin vị trí ở độ phân giải cao. Tuy nhiên, Mô hình 1 với chỉ số R^2 chỉ thấp hơn so với mô hình 2 nhưng lại đạt RMSE thấp nhất (4.8725), cho thấy khả năng kiểm soát sai số cực đoan tốt nhất trong nhóm — đây là tiêu chí quan trọng trong bài toán định giá thực tế, nơi các sai số lớn có thể gây rủi ro cao cho người dùng. Do đó, nhóm quyết định chọn **Mô hình 1** làm mô hình đại diện để trình bày demo ứng dụng.

5.2 Kiểm chứng chéo (Cross-Validation)

Toàn bộ quy trình huấn luyện và đánh giá được thiết kế để đảm bảo tính khách quan và khả năng tổng quát hóa của kết quả. Nhóm áp dụng chiến lược phân chia dữ liệu một lần (Hold-out Validation) với tỷ lệ 80/20 kết hợp **lấy mẫu phân tầng (Stratified Sampling)** theo đặc trưng `thanh_pho`, đảm bảo tỷ lệ vùng miền trong tập Train và tập Test là như nhau:

- **Tập huấn luyện (Train set — 80%):** 7.293 quan sát, được dùng để ước lượng toàn bộ các hệ số hồi quy và tính toán các thống kê phụ trợ (Target Encoding, giá trị lấp đầy trung vị, bản đồ mã hóa Phường). Tỷ lệ phân bổ: TP.HCM chiếm 72.02%, Hà Nội chiếm 27.98%.
- **Tập kiểm tra (Test set — 20%):** 1.823 quan sát, hoàn toàn không tham gia vào bất kỳ bước huấn luyện nào. Tỷ lệ phân bổ: TP.HCM chiếm 72.04%, Hà Nội chiếm 27.96%. Mọi chỉ số trong Bảng 5.1 đều được tính trên tập này.

Kết quả kiểm tra cho thấy tỷ lệ phân bổ giữa hai thành phố trong cả ba tập (toàn bộ, Train, Test) gần như đồng nhất hoàn toàn, xác nhận rằng chiến lược **Stratified Sampling** đã loại bỏ được nguy cơ thiên lệch vùng miền. Ngoài ra, toàn bộ thống kê phụ thuộc dữ liệu huấn luyện đều được tính riêng trên tập Train và áp dụng một chiều sang tập Test, đảm bảo không xảy ra hiện tượng rò rỉ thông tin **Data Leakage** trong quá trình so sánh chéo giữa 5 mô hình.

5.3 Điểm mạnh và Điểm yếu

Bảng 5.2 tổng hợp đánh giá định tính từng mô hình dựa trên ba tiêu chí: hiệu suất dự đoán, độ phức tạp triển khai và khả năng diễn giải (Interpretability).

Table 5.2: Đánh giá điểm mạnh và điểm yếu từng mô hình

Mô hình	**Điểm mạnh**	**Điểm yếu**
MH1 Log-Log, Poly & Interaction	Cấu trúc đơn giản, dễ diễn giải. RMSE thấp nhất (4.87). Tương tác Diện tích × Quận phản ánh tốt đặc thù thị trường.	Số chiều tăng khi thêm đa thức và tương tác. Không khai thác được vị trí dưới cấp Quận.
MH2 Target Encoding cấp Phường	R^2 và MAE tốt nhất (0.7551 / 2.60 Tỷ). Smoothed Encoding tránh overfitting. Cơ chế Fallback xử lý Phường mới ổn định.	MSE cao nhất (25.40). Quy trình encoding phức tạp, cần lưu bản đồ thống kê khi triển khai.
MH3 Poly bậc cao & Log-Log	Nắm bắt quan hệ phi tuyến nhờ `PolynomialFeatures` bậc 2. Tương tác Diện tích × cấu trúc nhà phản ánh quy luật thực tế.	R^2 và MAE kém hơn MH1, MH2 do tăng chiều quá mức. Khả năng diễn giải hệ số bị hạn chế.
MH4 Trích xuất đặc trưng văn bản	Khai thác tín hiệu từ tên đường và tiêu đề (`is_urgent`, `is_facade`). Phản ánh yếu tố thanh khoản và vị thế thương mại.	R^2 thấp nhất (0.7301), RMSE cao nhất (5.34). One-Hot Encoding tên đường làm tăng nhiễu và độ thưa thớt.
MH5 Spatial Interaction & KDE	KDE khử nhiễu thông minh, loại bỏ tin đăng ảo. Tương tác không gian toàn phần cho phép học hệ số đơn giá riêng theo Quận.	Số chiều tăng cao do tương tác toàn phần. Ngưỡng KDE cố định có thể loại nhầm bất động sản cao cấp hợp lệ.

Nhìn chung, điểm yếu chung của cả 5 mô hình là hiện tượng **Heteroscedasticity** (phương sai thay đổi): mô hình hoạt động ổn định và chính xác ở phân khúc nhà phổ thông (dưới 40 Tỷ VNĐ), nhưng sai số tăng đáng kể ở phân khúc cao cấp (trên 60 Tỷ VNĐ). Nguyên nhân cốt lõi là các biến số vật lý hiện có chưa bao hàm được các yếu tố định tính quyết định giá nhà hạng sang như chất lượng nội thất, lợi thế mặt tiền kinh doanh, và phong thủy — những thông tin vốn không có mặt trong dữ liệu rao bán thô.

6 Giải thích kết quả và góc nhìn sâu sắc (Interpretation and Insights)

6.1 Giải thích hệ số hồi quy (Interpreting Coefficients)

Do mô hình sử dụng thang đo Logarithm cho biến mục tiêu (*gia_log*), các hệ số hồi quy phản ánh tỷ lệ phần trăm thay đổi của giá nhà:

- **Diện tích (dien_tich_log):** Với hệ số 0.3509, khi diện tích tăng 1%, giá nhà trung bình tăng khoảng 0.35%. Kết hợp với biến bậc hai ($dien_tich_poly2 \approx 0.039$), ta thấy diện tích càng lớn thì giá trị cộng thêm trên mỗi mét vuông càng có xu hướng tăng mạnh (hiệu ứng tích lũy).
- **Số tầng (so_tang):** Mỗi tầng xây thêm làm giá trị căn nhà tăng khoảng 9.5% ($e^{0.0907} - 1$).
- **Pháp lý (phap_ly_Đã có sổ):** Những căn nhà đã có sổ hồng/sổ đỏ có giá trị cao hơn khoảng 17.6% so với các trường hợp chưa rõ pháp lý.

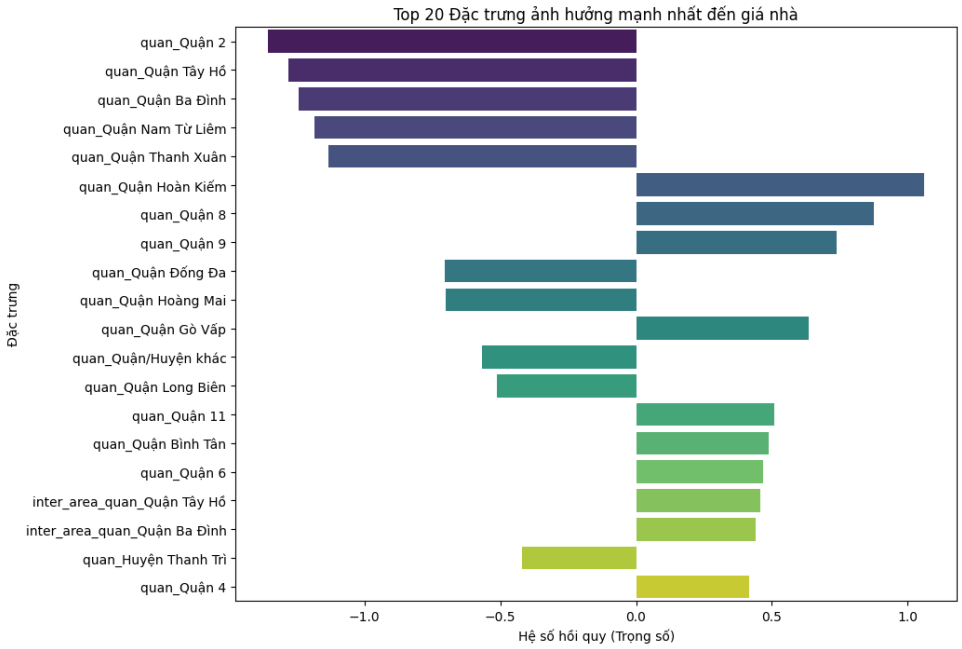

Figure 6.1: Top 20 Đặc trưng ảnh hưởng mạnh nhất đến giá nhà

Hệ số của Quận Hoàn Kiếm (1.06) đứng đầu bảng trọng số (Hình 6.1), khẳng định vị thế độc tôn về giá trị bất động sản tại lõi trung tâm thủ đô.

6.2 Yêu cầu cốt lõi

Xác định tầm quan trọng tương đối giữa Vị trí và Diện tích:

- **Vị trí là yếu tố tiên quyết (Primary Factor):** Như thể hiện trong Hình 6.2, mức giá trung vị của các quận trung tâm (Hoàn Kiếm, Tây Hồ) cao hơn hẳn so với ngoại ô. Vị trí quyết định "điểm khởi đầu" của giá nhà.
- **Diện tích là yếu tố nền tảng (Base Factor):** Hình 6.3 cho thấy mối quan hệ thuận chiều và phi tuyến giữa diện tích và giá. Diện tích chỉ thực sự bùng nổ về giá trị khi nằm ở các vị trí "đất vàng".
- **Kết luận:** Vị trí quan trọng hơn diện tích thuần túy, vì nó đóng vai trò là hệ số nhân cho tất cả đặc tính khác.

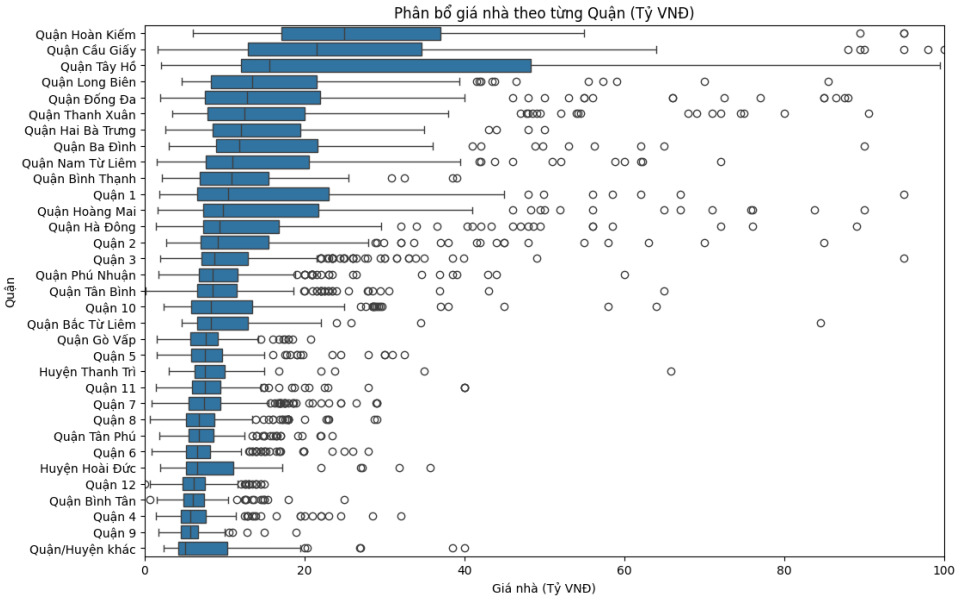

Figure 6.2: Phân bổ giá nhà theo từng Quận (Tỷ VNĐ)

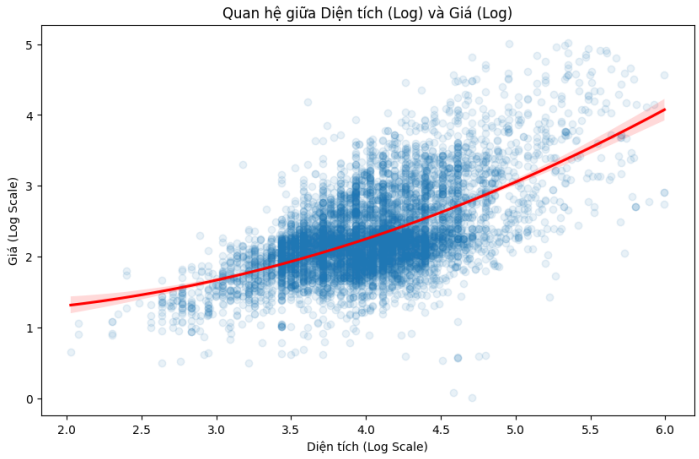

Figure 6.3: Quan hệ phi tuyến giữa Diện tích (Log) và Giá (Log)

6.3 Những phát hiện (Insights) từ mô hình

- **Sự chính xác theo phân khúc:** Biểu đồ sai số (Hình 6.4) có hình cái phễu (*Heteroscedasticity*). Mô hình hoạt động ổn định ở phân khúc nhà phổ thông (dưới 40 tỷ VNĐ), nhưng sai số tăng dần ở phân khúc cao cấp.
- **Khoảng trống dữ liệu cao cấp:** Với các bất động sản trên 60 tỷ VNĐ, giá trị còn phụ thuộc vào nội thất, phong thủy hoặc lợi thế mặt tiền kinh doanh mà các biến số vật lý hiện có chưa bao hàm hết.
- **Đặc thù thị trường:** Các quận trung tâm mới (Tây Hồ, Cầu Giấy) có dải giá biến động mạnh nhất, thể hiện tiềm năng đầu cơ cao. Ngược lại, các quận ngoại thành có dải giá hẹp, phản ánh thị trường nhu cầu ở thực ổn định.

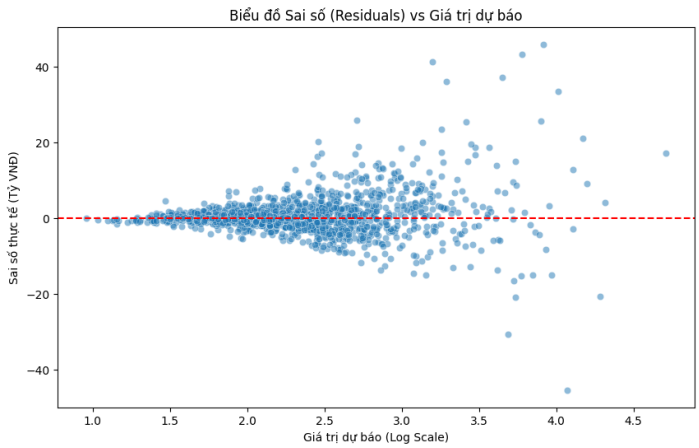

Figure 6.4: Biểu đồ Sai số (Residuals) vs Giá trị dự báo

7 Ứng dụng dự toán (Application Development)

7.1 Mô tả giao diện

Ứng dụng được xây dựng dưới dạng giao diện Web (Web Application), cho phép người dùng tương tác trực tiếp một cách trực quan và dễ dàng. Giao diện được thiết kế theo phong cách hiện đại với cấu trúc chia làm hai phần chính:

- **Khung nhập liệu (Input Panel):** Nằm bên trái, chứa các trường thông tin để người dùng tùy chỉnh thông số bất động sản gồm: diện tích, số phòng tắm, số tầng, quận, tình trạng pháp lý.
- **Khung hiển thị (Output Panel):** Nằm bên phải và phía dưới, dùng để trình bày kết quả dự báo và các biểu đồ phân tích dữ liệu chuyên sâu.

Cơ chế hoạt động của giao diện là "Dynamic Loading": Ban đầu hệ thống chỉ hiển thị các ô nhập liệu. Sau khi người dùng nhấn nút "Dự đoán", các thông tin về giá và biểu đồ mới được tính toán và hiển thị ra màn hình.

Figure 7.1: Giao diện nhập liệu ban đầu của hệ thống

7.2 Tính năng chính

Tính năng cốt lõi của ứng dụng là ước tính giá trị bất động sản dựa trên các đặc điểm kỹ thuật cụ thể. Quy trình tương tác bao gồm:

1. **Cung cấp thông tin:** Người dùng nhập các thông số bao gồm: Diện tích (m^2), Số phòng tắm, Số tầng, Quận/Huyện và Tình trạng pháp lý.

2. **Xử lý mô hình:** Hệ thống sử dụng mô hình học máy đã được huấn luyện để tính toán giá trị dựa trên các trọng số của các biến đầu vào.

3. **Trả về kết quả trực tiếp:** Kết quả được trả về ngay tại khu vực "Kết quả" với hai thông số quan trọng:

   - **Giá dự báo:** Giá trị ước tính của bất động sản (đơn vị: tỷ VNĐ).
   - **Độ tin cậy (R^2):** Thể hiện mức độ phù hợp của mô hình (trong giao diện hiện tại là 0.75).

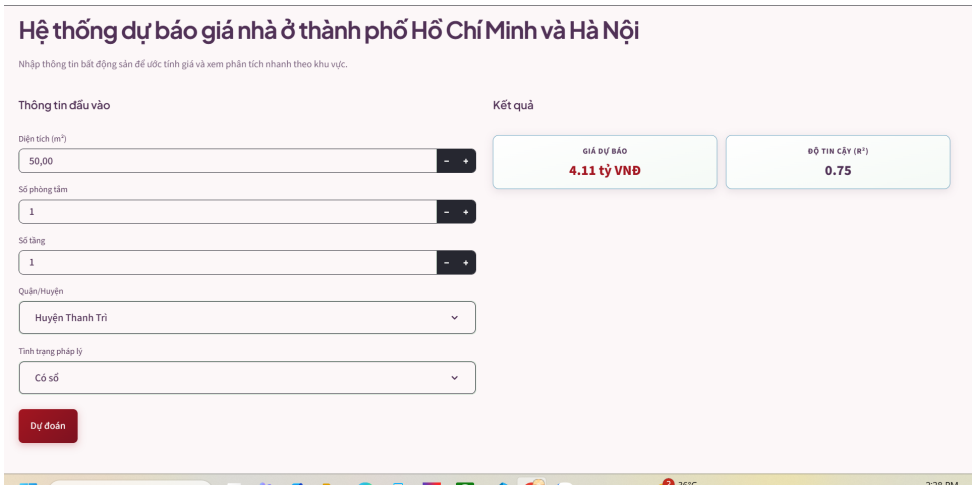

Figure 7.2: Kết quả dự báo giá và chỉ số đánh giá mô hình

7.3 Trực quan hóa kết quả

Để hỗ trợ người dùng có cái nhìn đa chiều về mức giá, hệ thống tự động xuất các biểu đồ so sánh trực quan so với thị trường tại khu vực (ví dụ: Huyện Thanh Trì):

- **Biểu đồ phân tán (Area vs Price):** Hiển thị vị trí của ngôi nhà (dấu sao đỏ) so với các giao dịch thực tế và đường xu hướng chung.
- **Biểu đồ mật độ (KDE Plot):** Cho thấy mức giá dự báo 4.11 tỷ VNĐ đang nằm ở vùng có mật độ giao dịch cao hay thấp trong khu vực.
- **Phân tích theo thuộc tính (Box-plot):** So sánh mức giá dự báo với dải giá phổ biến theo số lượng phòng tắm và tình trạng pháp lý.

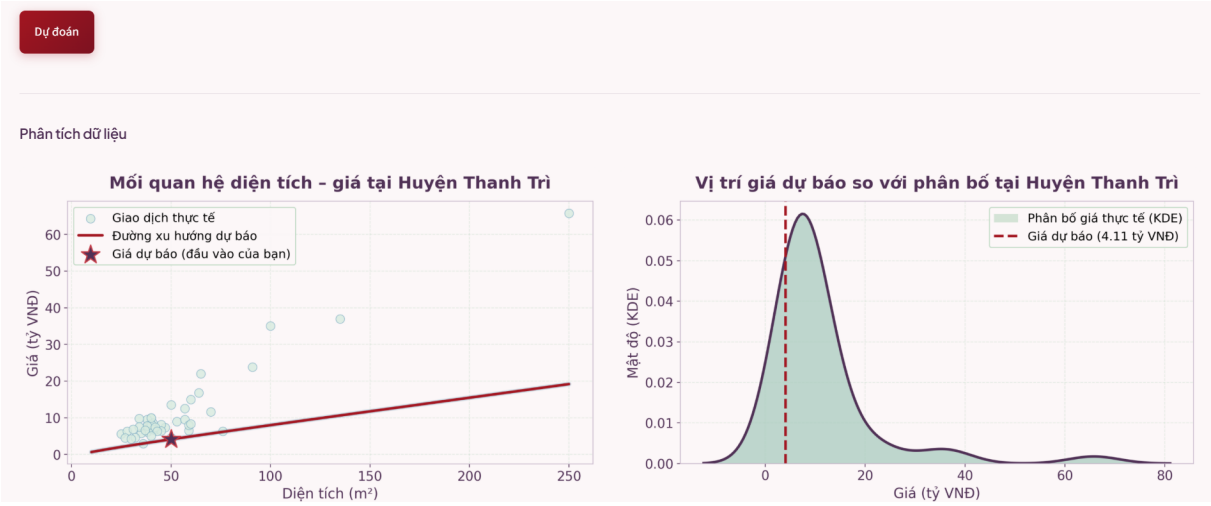

Figure 7.3: Phân tích mối quan hệ diện tích và mật độ giá

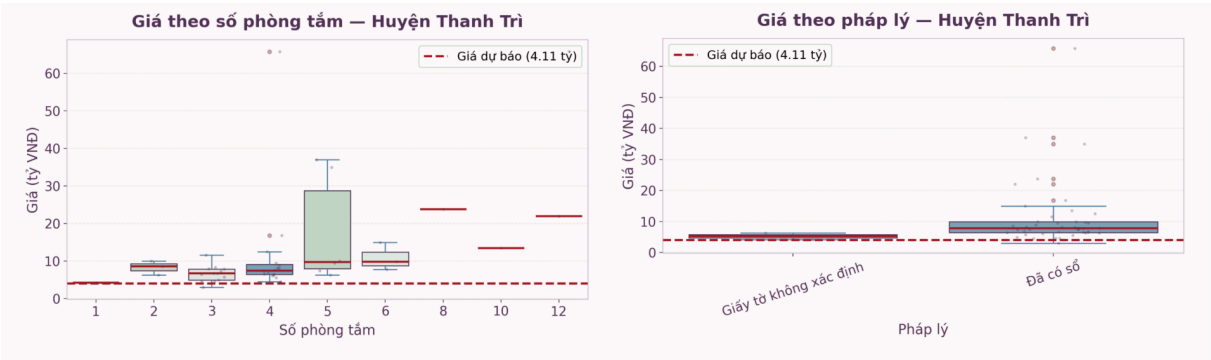

Figure 7.4: Phân tích giá theo phòng tắm và pháp lý

8 Kết luận (Conclusion)

8.1 Tổng kết kết quả đạt được

Đồ án đã hoàn thành mục tiêu xây dựng hệ thống dự báo giá bất động sản tại hai thành phố lớn là Hà Nội và TP. Hồ Chí Minh. Những kết quả chính bao gồm:

- **Lựa chọn mô hình triển khai:** Mặc dù mô hình 2 có chỉ số R^2 cao nhất, nhóm đã quyết định chọn **Mô hình 1 (Log-Log, Poly & Interaction)** để đóng gói lên giao diện ứng dụng. Lý do là MH1 sở hữu chỉ số **RMSE thấp nhất (4.87)**, cho thấy sai số trung bình thực tế nhỏ hơn và khả năng tổng quát hóa (Generalization) ổn định hơn khi đối mặt với dữ liệu thực tế từ người dùng.
- **Tối ưu hóa đặc trưng:** Việc kết hợp biến tương tác giữa Diện tích và Quận huyện trong mô hình 1 đã phản ánh chính xác quy luật giá trị "đất vàng" tại các vùng lõi trung tâm.
- **Sản phẩm thực tiễn:** Xây dựng thành công web app cho phép người dùng nhận dự báo giá ngay lập tức cùng hệ thống biểu đồ so sánh trực quan, giúp tăng tính minh bạch cho thông tin bất động sản.

8.2 Hạn chế của mô hình

Hệ thống vẫn còn một số điểm cần cải thiện:

- **Sai số phân khúc cao cấp:** Do hiện tượng phương sai thay đổi (Heteroscedasticity), mô hình chưa đạt độ chính xác kỳ vọng ở các căn nhà có giá trị cực lớn (trên 60 tỷ VNĐ) do thiếu các biến định tính như chất lượng xây dựng hoặc nội thất.
- **Dữ liệu đầu vào:** Các đặc trưng hiện tại mới chỉ dừng lại ở các thông số vật lý cơ bản của ngôi nhà, vì vậy chưa thể giải thích được các khía cạnh khác của một ngôi nhà để dự đoán chính xác hơn.

Tài liệu tham khảo

[1] Weisberg, S. (2014). *Applied Linear Regression*. 4th Edition. Wiley. Link: https://www.stat.purdue.edu/~qfsong/teaching/525/book/Weisberg-Applied-Linear-Regression-Wiley.pdf

[2] Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*.

[3] Đồ án Nhập môn khoa học dữ liệu HCMUS (23127083-23127190-23127408-23127493) Link: https://github.com/Thuongcdv123/Project-Intro-DS